EDA 与特征工程总结（阶段 1~2）

七张表 · 每张四段：包含的变量 / 处理方式 / 中间的问题 / 最后得到的特征

主线：把"一人多行"压成"一人一行"

模型要预测的 TARGET 是一人一行（307,511 人），但历史数据都是一人多行。特征工程做的唯一一件事，就是把一个人散落在几千行里的行为翻译成一行数字。万能三板斧：聚合（count/sum/mean/max）、比率（除以机会数，灵魂是分母）、时间窗口（最近 3/6/12 月 vs 更早，看恶化）。判断特征好坏：把它十分位分组，看每组违约率是否单调。

① application_train（申请主表） · 307,511 行 × 122 列 · 粒度 = 人

【包含的变量】

字段（组）	含义
SK_ID_CURR / TARGET	客户 ID / 违约标签（1=逾期困难，0=其他），全项目唯一的答案
AMT_INCOME_TOTAL / AMT_CREDIT / AMT_ANNUITY / AMT_GOODS_PRICE	收入 / 贷款额 / 年金 / 商品价
CODE_GENDER / CNT_CHILDREN / CNT_FAM_MEMBERS	性别 / 子女数 / 家庭人口
NAME_EDUCATION_TYPE / NAME_FAMILY_STATUS / NAME_INCOME_TYPE / NAME_HOUSING_TYPE / OCCUPATION_TYPE	学历 / 婚姻 / 收入类型 / 住房 / 职业（类别变量）
DAYS_BIRTH / DAYS_EMPLOYED / DAYS_REGISTRATION / DAYS_ID_PUBLISH	年龄 / 工龄 / 登记时长 / 证件时长（相对申请日的天数，负数=过去）
EXT_SOURCE_1 / 2 / 3	外部征信评分（归一化），最关键的三列
APARTMENTS_AVG/MODE/MEDI 等 40+ 列	居住建筑/区域的归一化信息（面积、房龄、电梯、楼层…）
AMT_REQ_CREDIT_BUREAU_HOUR/DAY/WEEK/MON/QRT/YEAR	申请前各时间窗内被查询征信的次数
OBS/DEF_30/60_CNT_SOCIAL_CIRCLE	社交圈中逾期的人数
FLAG_DOCUMENT_2~21 / FLAG_MOBIL / FLAG_EMP_PHONE / FLAG_EMAIL	是否提供了各类证件 / 手机 / 公司电话 / 邮箱

【处理方式】

1. 基础EDA：查307,511行、122列，确认SK_ID_CURR唯一；统计TARGET分布（违约率8.07%）和缺失率（41 个字段缺失 >50%）。
2. 单变量风险分层：对 EXT_SOURCE_1/2/3 十等分，看每组违约率；再算单变量 AUC。

3. 缺失关联分析：对比"某字段缺失 vs 不缺失"两组的违约率（Lift）。

【中间的问题】

▲ 类别不平衡：违约率仅 8.07%，决定后面不能用准确率当指标（全猜"不违约"也有 92%）。

▲ 缺失本身是弱信号：缺失客户违约率更高（Lift 1.05~1.06），但差距仅约 1 个百分点，不是决定性因子。

▲ 41 个字段缺失 >50%，处理时要区分"无记录 / 无有效分母 / 真实 0 / 信息未知"。

【最后得到的特征】

主表本来就是"一人一行"，120 个原始字段直接进模型，不额外做聚合（除 ID 和 TARGET 外全部保留）。真正有区分力的代表：EXT_SOURCE_1/2/3（单变量 AUC 0.666 / 0.656 / 0.679，覆盖率 43.6% / 99.8% / 80.2%）。

② previous_application（历史贷款申请） · 167 万行 · 粒度 = 申请事件

【包含的变量】

字段（组）	含义
SK_ID_PREV / SK_ID_CURR	历史申请 ID / 客户 ID
NAME_CONTRACT_STATUS	审批结果：Approved 批 / Refused 拒 / Canceled 取消 / Unused offer 未用
AMT_APPLICATION / AMT_CREDIT	申请金额 / 最终授信金额（可能被银行砍额度）
AMT_DOWN_PAYMENT / AMT_ANNUITY / AMT_GOODS_PRICE	首付 / 年金 / 商品价
DAYS_DECISION	审批日（相对申请日的天数，负数=过去）
CODE_REJECT_REASON / NAME_CONTRACT_TYPE / NAME_PORTFOLIO / CHANNEL_TYPE	拒绝原因 / 合同类型 / 产品线 / 获客渠道
CNT_PAYMENT / DAYS_FIRST_DRAWING / DAYS_LAST_DUE 等	期数 / 首次放款日 / 最后到期日等

【处理方式】

1. 审批状态打标：IS_APPROVED / IS_REFUSED / IS_CANCELED 三个独立 0/1（不合并）。
2. 时间窗口打标：APP_D090（近90天）、APP_PREV090（前90天）、APP_D365（近365天）。
3. 聚合到客户级：历史申请次数、获批/拒绝/取消次数、各窗口申请与拒绝次数、距最近申请天数。
4. 算比率：全历史拒绝率、近90天拒绝率、前90天拒绝率、两者之差（趋势）。
5. 金额特征：正申请金额均值/最大、获批/被拒申请金额均值、授信申请比、授信<申请的比例。

【中间的问题】

▲ 分母为 0：近 90 天没申请时，拒绝率 0÷0 要标成缺失（replace 0 → NaN），不能错算成 0。

▲ Canceled ≠ Refused：取消申请（客户自己放弃，金额常为 0）和被拒绝（银行不信任）业务相反，绝不合并。

▲ 授信申请比：授信 < 申请（比值 <0.99）说明银行砍了额度，本身就是风险信号。

▲ 趋势特征覆盖极低：PREV_REFUSED_RATE_DELTA_90V90 要"两个窗口都申请过"才能算，缺失 96.35%。

【最后得到的特征】（20 个）

特征	含义
PREV_APP_COUNT / APPROVED_COUNT / REFUSED_COUNT / CANCELED_COUNT	历史申请总次数 / 获批 / 被拒 / 取消次数
PREV_APP_D090 / PREV090 / D365	近90天 / 前90天 / 近365天申请次数
PREV_REFUSED_D090 / PREV090	近90天 / 前90天被拒次数
PREV_REFUSED_RATE / RATE_D090 / RATE_PREV090	全历史拒绝率 / 近90天拒绝率 / 前90天拒绝率
PREV_REFUSED_RATE_DELTA_90V90	近90天 vs 前90天拒绝率变化（趋势）
PREV_DAYS_SINCE_LAST_APP	距最近一次历史申请的天数
PREV_APP_AMT_MEAN / MAX	历史申请金额均值 / 最大
PREV_APPROVED_AMT_MEAN / REFUSED_AMT_MEAN	获批申请金额均值 / 被拒申请金额均值
PREV_APPROVED_CREDIT_RATIO_MEAN	授信申请比均值
PREV_APPROVED_CREDIT_LT_APP_RATE	授信 < 申请（被砍额度）的比例

③ bureau（外部征信主表） · 171 万行 · 粒度 = 账户

【包含的变量】

字段（组）	含义
SK_ID_CURR / SK_BUREAU_ID	客户 ID / 征信账户 ID（一个客户可有多个账户）
CREDIT_ACTIVE	账户状态：Active（未结清）/ Closed（已结清）等
CREDIT_TYPE / CREDIT_CURRENCY	信贷类型（消费贷/信用卡/车贷…）/ 币种
DAYS_CREDIT / DAYS_CREDIT_ENDDATE / DAYS_ENDDATE_FACT / DAYS_CREDIT_UPDATE	开户日 / 计划到期日 / 实际结束日 / 信息更新时间（相对申请日）
CREDIT_DAY_OVERDUE / AMT_CREDIT_MAX_OVERDUE	当前逾期天数 / 历史最大逾期金额
AMT_CREDIT_SUM / AMT_CREDIT_SUM_DEBT / AMT_CREDIT_SUM_LIMIT / AMT_CREDIT_SUM_OVERDUE	授信额 / 当前欠款 / 额度 / 逾期金额
CNT_CREDIT_PROLONG / AMT_ANNUITY	展期次数 / 年金

【处理方式】

1. 状态打标：IS_ACTIVE / IS_CLOSED 两个 0/1，分开统计。
2. 债务异常打标：DEBT_NEGATIVE（欠款为负）、ACTIVE_DEBT（活跃账户欠款，负值 clip 到 0）、ACTIVE_DEBT_MISSING（活跃账户欠款缺失）。
3. 聚合到客户级：账户总数、活跃/关闭账户数、活跃债务合计/最大、负债务账户数。
4. 算比率：活跃账户占比、活跃账户债务缺失率。
5. 时间窗口（先排除 DAYS_CREDIT_UPDATE>0 的记录）：近90/前90/近365天新开账户数、变化量、距最近信贷天数。
6. 静态补充：当前逾期账户数、最大当前逾期天数、逾期金额合计、消费贷/信用卡账户数。

【中间的问题】

▲ Active / Closed 风险天差地别，不能把"账户数"一锅端。

▲ 债务负值不能直接加进总欠款（会抵消正欠款），要 clip(lower=0) 再求和，负值单独当异常标记。

▲ "无记录 ≠ 欠款为 0"：所有活跃账户欠款都缺失的客户，总欠款设 NaN，不能填 0。

▲ 泄漏苗头：DAYS_CREDIT_UPDATE > 0（更新时间在申请之后）的 17 条记录要排除——申请时点不可能知道未来的更新。

【最后得到的特征】（bureau 19 + bureau_balance 8 = 27 个）

特征	含义
BUR_CREDIT_COUNT / ACTIVE_COUNT / CLOSED_COUNT	征信账户总数 / 活跃账户数 / 已关闭账户数
BUR_ACTIVE_DEBT_SUM / MAX	活跃账户欠款合计 / 最大
BUR_ACTIVE_RATIO	活跃账户占比
BUR_ACTIVE_DEBT_MISSING_RATE / NEGATIVE_DEBT_COUNT	活跃债务缺失率 / 负债务账户数
BUR_CREDIT_NEW_D090 / PREV090 / D365	近90天 / 前90天 / 近365天新开账户数
BUR_CREDIT_NEW_DELTA_90V90 / DAYS_SINCE_LAST_CREDIT	新开账户数变化 / 距最近信贷天数
BUR_CURRENT_OVERDUE_COUNT / MAX_CURRENT_DPD / OVERDUE_AMT_SUM	当前逾期账户数 / 最大逾期天数 / 逾期金额合计
BUR_CONSUMER_COUNT / CREDIT_CARD_COUNT	消费贷账户数 / 信用卡账户数
BUR_BB_RECORD_COUNT / EVER_OVERDUE_COUNT / MAX_STATUS	有月度历史账户数 / 曾逾期账户数 / 最大逾期等级
BUR_BB_OVERDUE_RATE_MEAN / WORSEN_COUNT / DELTA_MEAN	逾期比例均值 / 近期恶化账户数 / 趋势变化均值

④ bureau_balance（征信月度状态）· 2730 万行 · 粒度 = 账户 × 月

【包含的变量】

字段	含义
SK_BUREAU_ID	征信账户 ID（靠它才能把"月"归到"人"）
MONTHS_BALANCE	月份（相对申请日，-1=最近一个月）
STATUS	当月状态：0=正常，1~5=逾期 1~5 个月（越大越严重），C=关闭，X=未知

【处理方式】

1. 状态打标：IS_KNOWN（只把 0~5 当"明确状态"，X/C 排除）、IS_OVERDUE（1~5 逾期）、STATUS_NUM（把 X/C 转成 NaN）。
2. 第一级聚合（月 → 账户）：观察月数、明确状态月数、逾期月数、最大逾期等级、逾期比例、是否曾逾期。
3. 时间窗口（近6月 vs 前6月）：各窗口逾期比例，两者之差；只对"两个窗口都有≥2个明确状态月"的账户算趋势。
4. 第二级聚合（账户 → 人）：有月度历史的账户数、曾逾期账户数、最大逾期等级、逾期比例均值、近期恶化账户数、趋势均值。

【中间的问题】

▲ X（未知）和 C（关闭）都不是"正常还款 0"，只把 0~5 当"明确状态"做分母，否则逾期比例被稀释。

▲ 两级聚合不能跳级：月份只知道自己属于哪个账户，必须靠 bureau 的 SK_BUREAU_ID→SK_ID_CURR 映射把账户归到人。

▲ 171,269 个客户没有任何月度历史：计数特征填 0，但"最大逾期等级/逾期比例"保留 NaN（无记录 ≠ 0）。

▲ 趋势特征 BUR_BB_DELTA_MEAN 缺失约 76%（要双窗口都够月数）。

【最后得到的特征】（已并入 bureau，见上表 BUR_BB_* 8 个）

验证结果：违约率从"有历史未逾期 7.22%" → "曾逾期未恶化 9.41%" → "曾逾期且恶化 12.03%"，单调上升，证明两级特征造对了。

⑤ POS_CASH_balance（内部贷款月度逾期）· 1000 万行 · 粒度 = 贷款 × 月

【包含的变量】

字段	含义
SK_ID_PREV / SK_ID_CURR	历史贷款 ID / 客户 ID
MONTHS_BALANCE	月份（相对申请日）

字段	含义
CNT_INSTALMENT / CNT_INSTALMENT_FUTURE	总期数 / 剩余期数
NAME_CONTRACT_STATUS	合同状态（Active/Completed 等）
SK_DPD / SK_DPD_DEF	当月逾期天数 / 容忍口径逾期天数（小额逾期不计）

【处理方式】

1. 先解决粒度：一个人同月可能有多笔贷款，先聚合成"客户 × 月"的最大 DPD，避免同月重复计数。
2. 静态特征：历史最大/平均 DPD、逾期比例、≥30天逾期比例、观察月数。
3. 时间窗口：近 3/6/12 月的 DPD 均值、最大值、逾期比例、≥30天比例。
4. 趋势：近3月 vs 前3月，造原始 DPD 趋势、90天截尾 DPD 趋势、逾期频率趋势三个。
5. 连续逾期：从月份序列里找"最长连续逾期"、"当前连续逾期"、"恢复次数"。
6. 严重逾期新近度：距最近一次 >90 天逾期有多少个月。

【中间的问题】

▲ 极端 DPD：原始值可达几百天，一个值就带偏均值/趋势，要 90 天截尾并同时保留原始/截尾两版。

▲ 两种 DPD 口径（SK_DPD vs SK_DPD_DEF）不同，不能互相替代。

▲ 连续逾期要识别"真正相邻的日历月份"才算连续，不能只看排序相邻。

【最后得到的特征】（27 个）

特征	含义
POS_DPD_MAX_ALL / MEAN_ALL / RATE_ALL / DPD30_RATE_ALL / OBS_MONTHS_ALL	历史最大/平均 DPD、逾期比例、≥30天比例、观察月数
POS_DPD_MEAN/MAX/RATE/DPD30_RATE_M03・M06・M12	近 3/6/12 月的 DPD 均值/最大/逾期比例/≥30天比例
POS_DPD_MEAN_DELTA_3V3	近3月 vs 前3月 DPD 均值变化（趋势）
POS_DPD_CAP90_DELTA_3V3	90天截尾 DPD 趋势
POS_OVERDUE_RATE_DELTA_3V3	逾期频率趋势
POS_OVERDUE_STREAK_MAX / CURRENT	最长连续逾期 / 当前连续逾期月数
POS_DPD_RECOVERY_COUNT	从逾期恢复正常的次数
POS_MONTHS_SINCE_LAST_DPD90	距最近一次 >90 天逾期的月数

⑥ credit_card_balance（信用卡月度表现）· 384 万行 · 粒度 = 卡 × 月

【包含的变量】

字段（组）	含义
SK_ID_PREV / SK_ID_CURR / MONTHS_BALANCE	信用卡 ID / 客户 ID / 月份
AMT_BALANCE / AMT_CREDIT_LIMIT_ACTUAL	当月余额 / 实际信用额度（核心两列）
AMT_DRAWINGS_ATM/CURRENT/OTHER/POS_CURRENT + CNT_DRAWINGS_*	当月各类取现/消费金额与次数
AMT_INST_MIN_REGULARITY / AMT_PAYMENT_TOTAL_CURRENT	最低应还额 / 实际总付款
AMT_RECEIVABLE_PRINCIPAL / AMT_RECIVABLE / AMT_TOTAL_RECEIVABLE	应收本金 / 应收 / 总应收
CNT_INSTALMENT_MATURE_CUM / NAME_CONTRACT_STATUS	已还期数 / 合同状态
SK_DPD / SK_DPD_DEF	当月逾期天数 / 容忍口径逾期天数

【处理方式】

1. 额度使用率：UTIL_RAW = 余额 ÷ 额度（只对额度>0 的月份）；UTIL_CAP1 = 截尾到 0~1。
2. 异常打标：ZERO_LIMIT（额度=0）、OVER_LIMIT_VALID（额度>0 且余额>额度）、NEGATIVE_BALANCE（余额<0）。
3. 聚合：观察月数、账户数、使用率均值/最大、截尾使用率均值、超限比例、零额度比例、负余额次数、余额均值/最大。
4. 趋势：近3月 vs 前3月使用率变化（CC_UTIL_DELTA_3V3）。
5. 还款与逾期：最低应还覆盖率、付款不足比例、逾期比例、≥30天比例、最大 DPD、DPD_DEF 比例、截尾 DPD 均值、DPD 趋势。

【中间的问题】

▲ 零额度陷阱：额度=0 时"余额 ÷ 0"是无穷大，必须排除在分母外，使用率设 NaN。

▲ 超限 ≠ 零额度：额度>0 且余额>额度（真刷爆）和额度=0 是两回事，分别造特征。

▲ 截尾丢信息：使用率 clip 到 0~1 后"超限了多少"就没了，要同时保留原始/截尾/超限比例三个。

▲ 最低应还覆盖率 ≠ 逾期率：付款和账单统计周期不同；SK_DPD vs SK_DPD_DEF 口径不同。

【最后得到的特征】（31 个）

特征	含义
CC_OBS_MONTHS / ACCOUNT_COUNT	观察月数 / 信用卡账户数
CC_UTIL_MEAN_ALL / MAX_ALL / CAP1_MEAN_ALL	原始使用率均值/最大 / 截尾使用率均值
CC_OVERLIMIT_RATE_ALL / ZERO_LIMIT_RATE_ALL	超限比例 / 零额度比例
CC_BALANCE_MEAN_ALL / MAX_ALL	余额均值 / 最大

特征	含义
CC_UTIL_DELTA_3V3	近3月 vs 前3月使用率变化
CC_MIN_PAY_COVERAGE_MEAN / MIN_PAY_SHORT_RATE	最低应还覆盖率均值 / 付款不足比例
CC_DPD_RATE_ALL / DPD30_RATE_ALL / DPD_MAX_ALL / DPD_DEF_RATE_ALL	逾期比例 / ≥30天比例 / 最大DPD / DPD_DEF比例
CC_DPD_CAP90_MEAN / DPD_DELTA_3V3	90天截尾DPD均值 / DPD趋势

⑦ installments_payments（历史分期付款） · 1360 万行 · 粒度 = 付款事件

【包含的变量】

字段	含义
SK_ID_PREV / SK_ID_CURR	历史贷款 ID / 客户 ID
NUM_INSTALMENT_VERSION / NUM_INSTALMENT_NUMBER	分期版本 / 期次（两者一起唯一定位一期）
DAYS_INSTALMENT	应还日（相对申请日）
DAYS_ENTRY_PAYMENT	实际付款日（相对申请日）
AMT_INSTALMENT / AMT_PAYMENT	应还金额 / 实际付款金额

【处理方式】

1. 分期重构：按分期（贷款+版本+期次）分组、按付款日期排序、累计求和，找"累计付款第一次达到应还金额"的日期=足额还款日（金额比较用 0.01 容差）。
2. 足额付款延迟 = 足额还款日 − 应还日（负数提前、0 按时、正数延期）。
3. 三阈值：找达到 95% / 99% / 100% 的日期，分别算 PAY95_DELAY / PAY99_DELAY / FULL_PAY_DELAY。
4. 到期覆盖率：到期日（含）前累计付款 ÷ 应还金额，截尾到 0~1。
5. 聚合到客户级：分期数、延期比例、正向延迟均值/最大、≥30天比例、到期覆盖率均值、异常付款比例等。
6. 趋势：近90天 vs 前90天覆盖率变化（INS_COVERAGE_DELTA_90V90）。

【中间的问题】

▲ 小额尾款坑：还了 99.9 块、差 1 毛尾款拖几个月，"足额付款延迟"会飙到几百天但风险很低，所以造 95/99/100% 三阈值把"只差尾款"和"从头没还"分开。

▲ 幸存者偏差：只统计"最终还清"的分期，会漏掉最危险的"还不起"的人。

▲ 付款缺失 ≠ 未付款；观测截止日（到期才 5 天的分期不能和 90 天的比 30 天以上延期）。

▲ 提前还款不算延迟（延迟计 0，不是负数）。

【最后得到的特征】（24 个）

特征	含义
INS_INSTALLMENT_COUNT	历史分期总数
INS_LATE_RATE_ALL / DPD30_RATE_ALL	延期比例 / 延期>30天比例
INS_DPD_MEAN_ALL / MAX_ALL	正向延迟均值 / 最大
INS_LATE_DAYS_AVG_ALL / CAP90_AVG	平均延迟天数 / 90天截尾平均延迟
INS_DUE_COVERAGE_MEAN	到期日覆盖率均值
INS_PAYMENT_ANOMALY_RATE / MISSING_PAYMENT_COUNT	付款异常比例 / 付款缺失数
INS_UNCONFIRMED_COUNT / D090_COUNT	未确认足额分期数 / 近90天未确认数
INS_UNPAID30_COUNT_ALL / D180	到期30天仍未足额数（全历史 / 近180天）
INS_COVERAGE_DELTA_90V90	近90天 vs 前90天覆盖率变化

◆ 为什么这一步？

这张表埋了全项目最大的一颗雷——TO 泄漏：那些"付款结果"字段（后来到底还没还、还多少）很多发生在申请日之后，拿它预测违约就是用未来预测过去。所以阶段 3 大审计里20 个 installments"付款结果"特征被直接排除，这也是消融实验里 installments 贡献 ≈ 0 的原因——不是这张表没用，是它最值钱的"结果"特征被防泄漏原则拿掉了。

全景回顾：七张表，一条主线

数据表	粒度	核心字段	独门坑
application_train	人	EXT_SOURCE_1/2/3、收入、年龄	缺失是弱信号、类别不平衡
previous_application	申请事件	审批结果、申请/授信金额、DAYS_DECISION	分母为0、Canceled≠Refused、趋势96%缺失
bureau	账户	账户状态、欠款、DAYS_CREDIT_UPDATE	Active/Closed区分、债务负值、无记录≠0
bureau_balance	账户×月	STATUS(0~5/C/X)	两级聚合、X/C语义、无月度历史
POS_CASH	贷款×月	SK_DPD	客户-月去重、连续逾期、DPD截尾
credit_card	卡×月	余额、额度、SK_DPD	零额度陷阱、超限≠零额度、截尾丢信息
installments	付款事件	应还/实付日、应还/实付金额	事件重构、小额尾款、幸存者偏差、TO泄漏

产出与去向

● 五份历史模块合计 129 个客户级特征：POS 27、Installments 24、Bureau 27、Previous 20、Credit Card 31。

● 模型输入 = 120 个主表原始字段（主表本来就是一人一行）+ 129 个历史工程特征 = 249，其中 20 个 installments 泄漏特征在阶段 3 被排除，剩 229 进入建模。

● 阶段 3~8 做的事，本质就是把这 129 个特征"验货"：哪些真有用、哪些泄漏、每张表贡献多大。