阶段 3：多表融合与质量审计

把 6 张分散的特征表合并成一张模型宽表，并在建模前完成"体检"

一、这一步要做什么

以 application_train 为主表，按客户主键 SK_ID_CURR，把 5 份历史特征表（外部征信 bureau、分期付款 installments、POS/CASH、历史申请 previous、信用卡 credit_card）左连接上去，得到一张"申请字段 + 历史特征 + TARGET"的完整宽表。
融合结果：307511 行 × 251 列；坏样本率 8.07%。

二、为什么这一步必须先做

◆ 为什么这一步？
特征工程是分散在 6 张表里完成的。任何一张表在合并时漏行、重复行、出现重复列名或无穷大，都会把"脏数据"带进模型，而且等问题在 AUC 里暴露时已经很难追溯到是哪张表、哪个特征。所以正确顺序是：先融合、先体检、确认干净，再进入建模。

- 体检的 4 个问题，对应任务说明里"阶段 3 必须完成的检查"：行数、重复/类型、缺失口径、TO 泄漏。
- 这一步交付的 feature_audit.csv 是后续所有阶段的"单一事实来源"——哪些特征保留、哪些排除，只看这一张表。

三、四项检查的结果

检查项	结果	是否通过
合并后行数	307511 条（应 307,511）	√
主键重复	0 条重复 SK_ID_CURR	√
重复列名	0 个	√
含无穷大的列	0 个	√
全空列	0 个	√
目标列缺失	0 条	√

一个真实踩到的坑：bureau 重复列

bureau_features.parquet 其实已经把 bureau_balance 的 7 个 BUR_BB_* 特征合并进去了（27 列 = 20 个 bureau + 7 个 bureau_balance）。如果再把 bureau_balance_features.parquet 单独合并一次，就会出现 7 个重复列。所以融合时只合并 5 份文件，而不是 6 份。这正是"重复字段名检查"的价值。

四、缺失值：三种"空"不能混为一谈

合并后大量特征有缺失，但它们缺失的含义完全不同，处理方式也不同：

缺失原因	例子	正确表达
无历史记录	客户从没申请过分期，所以没有 installments 特征	NaN（树模型能天然处理）
无有效分母	信用卡额度为 0 的月份，使用率算不出来	用 *_OBS / *_VALID 计数列区分
真实结果为 0	近 90 天新增信贷数 = 0	0（不是缺失）

特征工程阶段已经用 INS_VALID_INSTALMENT_COUNT、CC_VALID_LIMIT_MONTHS、POS_OBS_MONTHS_*、BUR_BB_TREND_VALID_COUNT 这类"有效观察数"列把前两种情况区分开了。所以建模时：LightGBM 可以直接吃 NaN（树会自己学会"缺失"这一支），逻辑回归才需要显式填补。

五、T0 防泄漏：本次审计的重点

◆ 为什么这一步?

所谓 T0 泄漏，是指某个特征用到了"申请时点之后才能看到的信息"。如果把这类特征喂给模型，验证集 AUC 会虚高，因为它相当于"开了天眼"。在风控场景这尤其危险：真实上线时你根本没有未来信息，模型会失效。

时间窗口的约定（检查结论）

各脚本的"近 N 天/月"窗口统一用 [-N, -1]，即排除 T0 当天。例如分期"近 90 天"= DAYS_INSTALMENT ∈ [-90, -1]，"前 90 天"= [-180, -91]；POS/信用卡"近 3 个月"= MONTHS_BALANCE ∈ [-3, -1]。所以这些历史窗口特征是 T0 安全的。

真正的泄漏点：分期付款的"付款结果"

分期付款表里，"是否足额付款 / 延期多少天 / 覆盖率"依赖"最终付款日"。但最终付款可能发生在 T0 之后（数据里确实存在 DAYS_ENTRY_PAYMENT > 0 的付款记录）。对"贷款还没结清"的客户，这些特征等于偷看了未来。

处理：把 20 个此类特征标记为 HIGH 风险，建模前排除；其余标记为 LOW（保留）。另有 6 个"当月边界/极小规模更新"特征标为 MEDIUM，保留但留待消融验证。

风险级别	含义	动作	特征数
HIGH	依赖 T0 之后才能观察的信息	排除	20
MEDIUM	极小规模或当月边界争议	保留 + 打标	6
LOW	只用 T0 之前的信息	保留	223

六、交付物与下一步

- outputs/data/wide_table.parquet —— 融合后的完整宽表（不删任何信息）。
- outputs/data/feature_audit.csv —— 每个特征的模块、缺失率、泄漏等级、保留/排除动作。
- outputs/metrics/fusion_audit.json —— 质量检查的汇总数字。

下一步（阶段 4）：基于 feature_audit.csv 里 action=KEEP 的特征，做分层训练/验证划分与预处理。

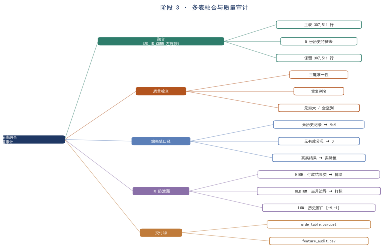
阶段 3 · 多表融合与质量审计
表融合
审计
融合
(SK_ID_CURR 左连接)
主表 307,511 行
5 份历史特征表
保留 307,511 行
质量检查
主键唯一性
重复列名
无穷大 / 全空列
缺失值口径
无历史记录 → NaN
无有效分母 → 0
真实结果 → 实际值
T0 防泄漏
HIGH: 付款结果类 → 排除
MEDIUM: 当月边界 → 打标
LOW: 历史窗口 [-N,-1]
交付物
wide_table.parquet
feature_audit.csv

图：阶段 3 思维导图