阶段 4：数据集划分与预处理

分层划分训练/验证集，并为两种模型做各自的预处理

一、这一步要做什么

先把 229 个保留特征 + TARGET 划分成 80% 训练集 / 20% 验证集，再分别准备两套预处理：一套给 LightGBM，一套给逻辑回归。
划分结果：训练集 246008 行、验证集 61503 行；坏样本率分别为 8.07% 和 8.07%，几乎一致。

二、为什么要分层划分（Stratified Split）

◆ 为什么这一步？
坏样本率只有 8.07%，样本高度不平衡。如果纯随机划分，验证集里可能分到极少甚至 0 个坏样本，那么 AUC/KS 这些指标就测不准，甚至无法计算。分层划分保证训练集和验证集里坏样本比例都≈8%，评估才公平、稳定。

另外固定随机种子（random_state=42），是为了让每次运行划分结果完全一样——模型结果可复现，是面试时最容易被追问、也最能体现专业度的细节之一。

三、为什么预处理要"只在训练集拟合"

◆ 为什么这一步？
填补用的中位数、标准化用的均值方差、编码用的类别取值表，都是从数据里"学"出来的参数。如果先把整份数据预处理再划分，验证集的信息就混进了训练集——这是最常见、最隐蔽的数据泄漏。正确做法永远是：先划分 → 只在训练集 fit → 再用同一套参数 transform 验证集。

代码里 LightGBM 的 OrdinalEncoder 和逻辑回归的 Pipeline 都是先 fit_transform(X_train)再 transform(X_valid)，严格遵循这条原则。

四、为什么两种模型要两套预处理

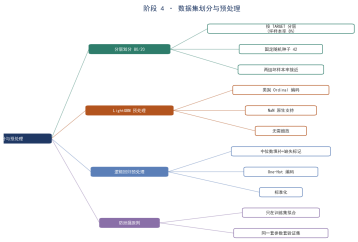
预处理步骤	LightGBM	逻辑回归	原因
缺失值	原生支持 NaN	中位数填补 + 缺失标记	树能对 NaN 分裂；线性模型必须有数值
类别变量	Ordinal 编码	One-Hot 编码	树可比较大小序；线性模型需要 0/1 哑变量
数值缩放	不需要	需要标准化	树只看切分点；线性模型受量纲影响
非线性	自动学习	需要显式构造	树的本质 vs 线性模型

注意逻辑回归加了"缺失标记"（add_indicator=True）：因为 EDA 已发现"信息缺失本身"与违约风险有关，这个 0/1 标记让线性模型也能利用缺失信息，而不只是用中位数糊一个值。

五、交付物

- train_lgb/valid_lgb.parquet —— LightGBM 用的特征（类别已编码，数值保留 NaN）。
- train_lr/valid_lr.npz —— 逻辑回归用的稀疏矩阵（one-hot 展开后约数百维）。
- lgb_ordinal.joblib / lr_preprocessor.joblib —— 保存的编码器与预处理流水线，供后续复现。

▲ 注意：ONE-HOT 展开后逻辑回归的特征数会明显多于原始 229 列（类别变量被拆成多个 0/1 列），这是正常现象，不是数据出错。



图：阶段 4 思维导图