阶段 5：建立 LR + LightGBM 基线

先跑出一个可靠的验证集 AUC，再建立可解释的线性对照

一、这一步要做什么

在预处理好的数据上训练两个"基线"模型：一个梯度提升树 LightGBM，一个逻辑回归 LR，用验证集 AUC 作为它们的第一份成绩单。

模型	训练 AUC	验证 AUC	说明
LightGBM	0.8831	0.7794	最佳迭代 668
逻辑回归	0.7703	0.7683	C=1.0, balanced

二、为什么先跑 LightGBM

◆ 为什么这一步？

我们构造的大多是数值型聚合特征。树模型能直接处理 NaN（对缺失值单独分裂）、自动学非线性交互，所以它能在最短时间里告诉我们"这些特征到底有没有预测价值"。拿到可靠的 AUC 后，再建 LR 作为可解释的对照，看变量如何线性地影响违约。

三、两个模型的关键差异

维度	LightGBM	逻辑回归
模型本质	集成决策树，非线性	线性模型，可解释
缺失值	原生支持 NaN	已中位数填补+标记
类别变量	Ordinal 编码	One-Hot 编码
缩放	不需要	已标准化
类别不平衡	样本加权(内置)	class_weight=balanced
解释性	特征重要性/SHAP	系数正负可直接看

四、怎么判断结果好不好

两个模型的验证 AUC 分别是 0.7794（LightGBM）和 0.7683（LR）。

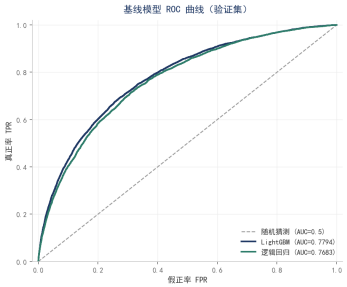
- AUC 越接近 1 越好；0.5 等于瞎猜。风控场景验证 AUC 0.75+ 已经是有区分度的水平。
- 训练 AUC 与验证 AUC 的差距反映过拟合：差距越小越好。LightGBM 用了早停(early stopping)防止过拟合。
- LR 明显低于 LightGBM 是正常且预期的——线性模型没有能力学复杂的非线性关系，它的价值在于"可解释"。

▲ 注意：这里的验证集既用于早停又用于报 AUC，会略微乐观。更严格的做法是用交叉验证（阶段 6），在完全没碰过的折上评估，得到无偏的泛化估计。

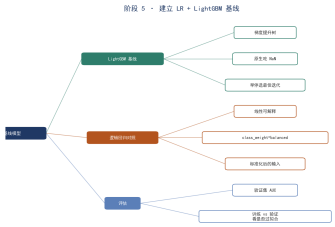
五、交付物与下一步

- outputs/models/lgb_baseline.joblib、lr_baseline.joblib —— 训练好的模型。
- outputs/data/pred_lgb_valid.npy、pred_lr_valid.npy —— 验证集预测概率，供后续画曲线。
- outputs/figures/baseline_roc.png —— 两模型 ROC 曲线对比。

下一步（阶段 6）：用 StratifiedKFold 交叉验证得到稳定的 OOF AUC，聚合特征重要性，并据此去除冗余 / 低贡献的变量。



图：基线模型 ROC 曲线



图：阶段 5 思维导图