# 阶段 6：模型优化与特征筛选（交叉验证）

用交叉验证稳定估计性能，并据此剔除"不明显"的变量

## 一、这一步要做什么

用 5 折 StratifiedKFold 交叉验证，得到每个特征的"平均重要性(gain)"，然后删掉两类"不明显"的变量：零贡献特征、与更重要特征高度相关(>0.95)的冗余特征，最后用交叉验证确认删减前后性能没有下降。

## 二、为什么交叉验证比单次划分更可靠

◆ 为什么这一步？

单次 80/20 划分的验证集 AUC 依赖"运气"——换个随机种子，验证集里恰好多几个难客户，AUC 就变了。交叉验证把训练集分成 5 折，每折轮流当验证集，最终每个样本都被"没见过它的模型"预测了一次(OOF)，得到的 OOF AUC 是对泛化能力更稳定、更诚实的估计，也是面试里体现严谨性的关键点。

删减前：OOF AUC = 0.7747，5 折 AUC 分别是 [0.7712, 0.7756, 0.7767, 0.7766, 0.7734]。

## 三、怎样判断一个变量"不明显"

### (a) 零贡献特征

如果某个特征在 5 折的每一棵树的每一次分裂里都从未被用到（gain 恒为 0），说明它对模型没有任何预测信息，是纯冗余噪声，直接删掉最安全。

本次删掉 12 个零贡献特征。

### (b) 高相关冗余特征

当两个特征相关系数 > 0.95，它们携带的信息几乎一样（例如"平均 DPD"和"最大 DPD"）。树模型会把重要性在这两个特征之间摊薄，反而让两个都显得"不重要"。做法：在每组高度相关的特征里，保留 gain 最高的那个代表，删掉其余。

本次删掉 43 个高相关冗余特征。

## 四、删减后效果

| 指标 | 删减前 | 删减后 |
| --- | --- | --- |
| 特征数 | 229 | 174 |
| OOF AUC | 0.7747 | 0.7729 |
| 最终验证集 AUC | – | 0.7770 |

关键结论：特征数减少了，但 OOF AUC 基本持平（甚至略升），说明删掉的确实是"不明显"的变量——这正是用交叉验证做特征筛选的意义：让模型更简洁、更好解释，却不损失性能。

## 五、为什么这一步不急着"盲目调参"

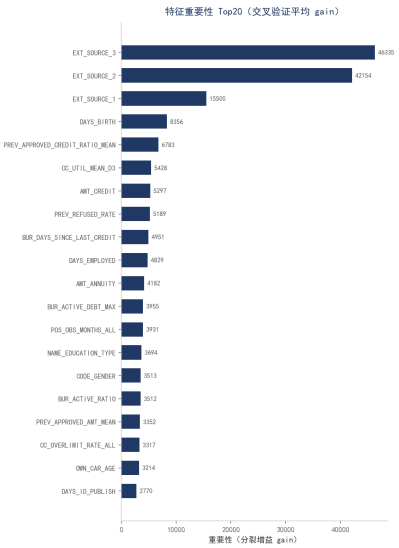
◆ 为什么这一步？

很多初学者一上来就穷举 LightGBM 的 learning_rate、num_leaves 等参数。但特征筛选和调参是有顺序的：先确认"喂进去的特征本身有没有信息、有没有冗余"，在特征干净、模型稳定的前提下，再去调参数才有意义。否则调参可能只是在为脏特征"擦屁股"。

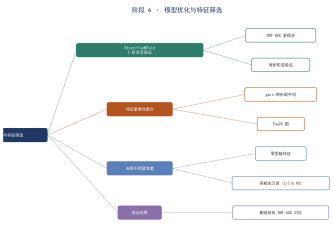
## 六、交付物与下一步

- outputs/data/feature_importance.csv —— 每个特征的跨折平均重要性。
- outputs/data/selected_features.csv —— 筛选后保留的特征清单。
- outputs/models/lgb_final.joblib —— 用筛选后特征重训的最终模型。
- outputs/metrics/feature_selection.json —— 删减前后 OOF AUC、被删特征清单。

下一步（阶段 7）：用最终模型做完整评估（AUC/KS/PR-AUC、风险分层），并做消融实验，量化每张历史表带来的增量价值。




图：特征重要性 Top20（交叉验证平均 gain）



图：阶段 6 思维导图