阶段 7：模型评估与消融实验

回答两个问题：模型效果有多好？每张历史表到底帮了多少？

一、模型效果：三个指标分别回答什么

指标	数值	回答的问题
ROC-AUC	0.7770	模型能否把高风险客户排在低风险客户之前？
KS	0.4174	好坏样本累计分布的最大差异有多大？
PR-AUC	0.2718	对少数坏样本的识别表现如何？

◆ 为什么这一步？

坏样本率只有 8%，是典型的不平衡分类。此时 AUC 会被大量好样本"稀释"，而 PR-AUC（精确率-召回率曲线下面积）更关注少数坏样本，能更真实地反映风控价值。所以三个指标要一起看，而不是只看 AUC。

过拟合检查：训练 AUC 0.8437 vs 验证 AUC 0.7770，差距 0.0667，属于树模型的正常水平（后续可用更强正则或更少叶子数再压）。

二、风险十分位分层：模型排序能力最直观的证明

把验证集客户按预测违约概率从低到高分成 10 组，看实际坏样本率是否逐组单调上升。如果第 10 组（最高风险）的实际坏样本率远高于第 1 组，说明模型的"排序"是有效的。

风险分位	实际坏样本率	预测均值	样本数
1	0.98%	0.013	6151
2	1.87%	0.020	6150
3	2.54%	0.027	6150
4	3.19%	0.034	6150
5	4.11%	0.043	6151
6	5.76%	0.055	6150
7	7.28%	0.072	6150
8	10.23%	0.098	6150
9	15.12%	0.145	6150
10	29.65%	0.292	6151

三、消融实验：每张历史表的真实增量

◆ 为什么这一步？

单变量分析只能说明"这个特征单独看和违约有关"，但放进模型后可能被别的特征取代、没有增量。消融实验保持划分、指标、训练流程完全一致，只去掉某个模块，看 AUC 变化，才能量化"这一模块在模型里的真实增量贡献"。

实验设计：全模型(F) vs 仅申请主表(A) vs 全模型分别减去 POS / installments / bureau / previous / credit_card。

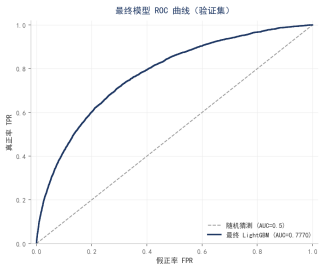
配置	AUC	特征数
仅申请主表 (A)	0.7588	78
全模型 (F)	0.7770	174
全模型 - pos	0.7746	153
全模型 - installments	0.7770	170
全模型 - bureau	0.7751	149
全模型 - previous	0.7721	154
全模型 - credit_card	0.7749	148

各模块边际贡献（全模型 AUC - 去掉该模块后 AUC）：

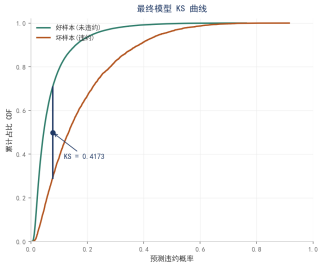
模块	边际贡献
pos	+0.0024
installments	-0.0000
bureau	+0.0019
previous	+0.0049
credit_card	+0.0021

四、交付物

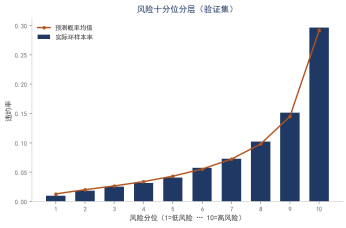
- outputs/figures/final_roc.png、final_ks.png、risk_deciles.png —— 三张评估图。
- outputs/figures/ablation_marginal.png —— 各模块边际贡献图。
- outputs/metrics/evaluation_metrics.json、ablation_results.json —— 完整数字。



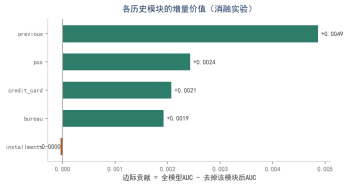
图：最终模型 ROC 曲线



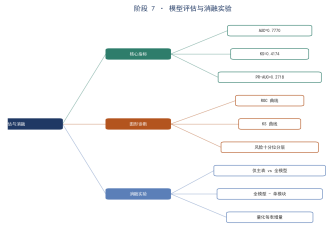
图：最终模型 KS 曲线



图：风险十分位分层



图：各历史模块边际贡献



图：阶段 7 思维导图