Home Credit 信贷风控项目 · 完整总结

从原始数据到可评估模型的完整链路（阶段 1－8）

一、项目概览

基于 Home Credit 的信贷申请数据，构建"客户是否会违约"的信用风险模型。共 307511 名申请客户，坏样本率 8.07%（不平衡分类）。数据包含 1 张申请主表 + 6 张历史行为表（外部征信、分期付款、POS/CASH、历史申请、信用卡、征信月度状态）。

二、方法与流程

1. 业务理解与数据探索：7 张表的粒度、业务含义、单变量风险区分度。
2. 多表特征工程：从付款事件→分期、月度征信→信用记录、信用记录→客户，逐层聚合出候选特征。
3. 多表融合与质量审计：按 SK_ID_CURR 左连接，保留全部申请；完成主键/重复列/无穷大检查与 TO 防泄漏分级。
4. 数据集划分与预处理：分层 80/20 划分，LightGBM 与逻辑回归两套预处理（只在训练集拟合）。
5. 基线建模：LightGBM + 逻辑回归，拿到首轮验证 AUC。
6. 交叉验证与特征筛选：5 折 StratifiedKFold 得到 OOF AUC，剔除零贡献与高相关冗余特征。
7. 评估与消融：AUC/KS/PR-AUC + 风险分层 + 模块消融。

三、关键结果

指标	数值	说明
LightGBM 验证 AUC	0.7794	基线
逻辑回归验证 AUC	0.7683	可解释对照
交叉验证 OOF AUC（删减前）	0.7747	更稳的泛化估计
交叉验证 OOF AUC（删减后）	0.7729	特征 229→174
最终模型 AUC	0.7770	验证集
KS	0.4174	好坏样本区分度
PR-AUC	0.2718	对少数坏样本的识别

四、消融结论：哪张历史表最有用

保持划分、指标、训练流程一致，去掉单个模块看 AUC 下降（边际贡献）：

模块	边际贡献	含义
previous	+0.0049	贡献最大
pos	+0.0024	
credit_card	+0.0021	
bureau	+0.0019	
installments	−0.0000	

结论：历史模块合计把 AUC 从"仅主表"的 0.7588 提升到全模型 0.7770，其中「previous」模块边际贡献最大（+0.0049），说明多表特征工程确实带来了模型无法从主表单独得到的风险信息。

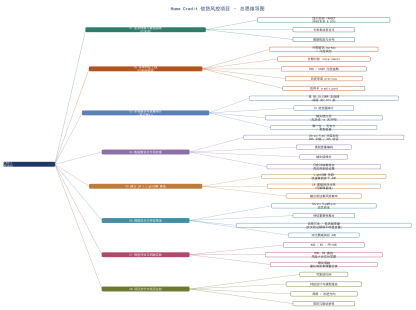
五、T0 防泄漏与数据质量

融合后 307511 行、主键无重复、无重复列、无无穷大、无全空列。T0 泄漏审计中标记 67 类问题特征：

- 20 个 HIGH 风险特征（分期付款"付款结果"类，依赖 T0 之后才能观察的最终付款）——建模前排除。
- 6 个 MEDIUM 风险特征（征信当月边界 / 极小规模更新）——保留但打标。
- 12 个零贡献特征、43 个高相关冗余特征——交叉验证后剔除。

六、局限与改进方向

- 防泄漏是"保守排除"而非"重新计算"：理想做法是用 T0 截止日重算分期付款特征（只保留 DAYS_ENTRY_PAYMENT<=0 的付款）。
- 逻辑回归可升级为 WOE 分箱 + 评分卡，得到可直接解释的信用评分。
- 可加入更细的客户-月份加权聚合、额度/逾期趋势交互特征（P2 阶段）。
- 可用 SHAP 做单客户解释，回答"为什么这个客户被拒"。



图：项目总思维导图